

2026 年臺灣國際科學展覽會

區 別： 中區

科 別： 電腦科學與資訊工程

作品名稱： A Multimodal AI System for Aphasia Patients Enabling
Fluent Expression Featuring Simulated Data Generation and
Optimized Real-Time Performance

關 鍵 詞： 失語症、多模態、自然語言處理

編 號：

摘要

非流暢型失語症患者理解力大致保留，卻因語言表達受損而溝通困難。本研究開發 AphaSpeak，一套整合於 iOS 的多模態 AI 溝通系統，融合語音與唇讀、環境、手勢與表情及個人化特徵，經大型語言模型重建患者意圖。於 AphasiaBank 臨床訪談評估，達 Cosine Similarity 0.91、Top-3 重建準確率 80%，較純文字 LLM 高約 10%。為低成本本地部署，以 Choice-Filtered Distillation 將 Gemini 2.5 Flash 蒸餾至 14B 本地模型，BLEURT-20 較教師高 0.04；並採用非同步串流架構，結合 ORB 關鍵幀與分層任務排程，將延遲壓至 4 秒內，驗證技術可行性。

Abstract

Individuals with non-fluent aphasia, such as Broca's aphasia and transcortical motor aphasia, largely retain comprehension yet face severe communication barriers due to impaired verbal expression. This research develops AphaSpeak, a multimodal AI communication system integrated into an iOS application. It fuses four modalities — speech and lip-reading, environmental imagery and ambient audio, gestures and facial expressions, and patient-specific personalized features — and uses a Large Language Model to generate ranked candidate sentences that reconstruct the patient's intended meaning. Evaluated on AphasiaBank clinical interviews, AphaSpeak achieves a Cosine Similarity of 0.91, a BLEURT-20 of 0.61, and 80% Top-3 reconstruction accuracy, exceeding a text-only LLM baseline by about 10%. To enable cost-effective local deployment, Choice-Filtered Distillation compresses Gemini 2.5 Flash into a ~14B local model that surpasses its teacher by +0.04 on BLEURT-20. AphaSpeak further adopts an asynchronous streaming architecture, complemented by ORB-based keyframe extraction and priority-aware task scheduling, reducing end-to-end latency to under 4 seconds. These results on the AphasiaBank dataset establish the technical feasibility of the system.

壹、研究動機

家人曾提及，對於某位知名好萊塢影星因罹患失語症而不得不息影一事感到惋惜。在對失語症有了更多了解後，我們不禁好奇近年來快速發展的人工智慧模型，是否能夠為這些病患提供協助，減輕他們的生活負擔？

失語症患者因中風、腦部創傷等原因，喪失用言語表達思想的能力，無法順暢與他人溝通。這種溝通困難對照顧者和患者都是巨大的挑戰。醫護人員在照顧失語症患者時，通常需借助肢體語言、圖片或繪圖等方式輔助，但這些方法仍有局限性，難以準確理解患者的想法。

隨著人工智慧、大型語言模型（LLM）和 Generative Pre-trained Transformer（GPT）的快速發展，解決失語症患者的溝通問題出現了新契機。本研究的目標是開發一款 iOS App，結合多模態 LLM 架構，協助醫護人員更精確地理解失語症患者需求，從而提升溝通流暢與效率。

貳、 研究目的

本研究目的在於打造一套針對非流暢型失語症患者的輔助溝通技術，提升他們表達時的語句流暢度與語意準確性。

參、 文獻回顧

一、失語症

失語症（Aphasia）是一種由大腦損傷引起的語言障礙，影響個體的言語表達、理解、閱讀和書寫能力。大多數情況下，這種損傷發生在大腦左半球的語言處理區域，原因包括中風、頭部創傷、腦腫瘤等。根據語言表現特徵，失語症大致可分為流暢型失語症（Fluent Aphasia）與非流暢型失語症（Non-Fluent Aphasia）。

（一）流暢型失語症：患者能夠流利地說話，但語言內容可能缺乏意義，詞語錯誤頻繁，甚至可能包含無關或自創的詞彙。在理解能力方面，不同亞型間存在明顯差異——如韋尼克（Wernicke's）失語症患者的語言理解嚴重受損，難以準確理解對話內容；而傳導型（Conduction）及命名型（Anomic）失語症患者則大致保有理解能力，主要困難集中在複述或詞彙提取上。

（二）非流暢型失語症：患者在表達上較為困難，說話緩慢、句子簡單且結構不完整，通常僅能使用少量詞語來傳達訊息。然而，他們的語言理解能力大多保持正常，因此能夠理解他人的話語。

其中，失語症若按照是否講話流利、是否能理解他人言語、是否能再重複一遍別人說的

話，還可細分為以下幾種，如下圖所示：




圖 3-1：失語症種類（修改自 National Aphasia Association [1]）

本研究的目標是「將患者不流暢的話語還原為流暢語句」，因此系統能夠幫助的對象僅限於非流暢型的失語症，也就是布洛卡失語症（Broca's Aphasia）以及跨皮質運動型失語症（Transcortical Motor Aphasia）。兩者主要的差別僅在於複述能力，其破碎、緩慢、夾雜語音錯誤的說話症狀皆可利用本研究開發之系統輔助。至於流暢型失語症，由於患者本身能說出完整句子但語意錯亂，問題本質與「還原破碎口語」不同，不在本研究範圍。

二、現有失語症溝通輔助方式[2]

- (一) 視覺輔助：患者雖然口語表達受限，但對圖片的辨識能力大多保留。臨床上常使用相關場景的圖片作為提示，協助患者建立語言聯想或直接以圖片代替口語表達。
- (二) 繪畫輔助：部分患者能透過自己動筆繪圖傳達想法，相比文字，繪畫對失語症患者而言更易理解，因而成為一種有效的溝通工具。
- (三) 手勢輔助：常見手勢如點頭、搖頭、指向目標物、或模仿吃飯喝水等動作。
- (四) 裝置輔助：患者也可利用市面上的替代溝通系統(AAC)。以 Proloquo2Go [3] 為例，患者透過螢幕上的圖卡，逐一點選符號來組合句子，再由系統合成語音播放。




圖 3-2：Proloquo2Go 圖卡介面（來源：AssistiveWare [3]）

然而這類系統依然有以下侷限：

1. 認知負擔高：患者需要記憶各個圖卡、文字所在的位置與分類才能實現組句，有較高的上手成本與使用負擔。
2. 組句速度過慢：圖卡接龍式的輸入速度過慢，跟不上自然對話的節奏。
3. 個人化能力不足：圖卡內容由系統預先定義，無法依使用者所在的家庭、工作場景自動生成或擴充。

本研究主要目標是以手機 App 作為輔助設備，讓患者只需自然表達，由系統從多模態線索推斷意圖，並將其還原為流暢的語句，嘗試解決失語症患者溝通問題。

三、近期對失語症的自然語言處理研究

近年將自然語言處理（NLP）方法應用於失語症語句還原的研究逐漸增多，整理如下表：

表 3-1：失語症的自然語言處理研究比較表

	Van Vaals et al. (2025) [4]	Shi et al. (2025) [5]	Manir et al. (2024) [6]
資料集	臨床數據集 + 基於詞性規則的合成數據	結合提示詞工程的 LLM 合成	AphasiaBank 資料庫轉錄文本
語句還原方法	使用合成數據微調 T5 和 FLAN T5	ASR-LLM	微調 BERT（遮罩預測）
模態	單模態：人工標註的轉錄文本。	單模態：語音轉文字。	單模態：人工標註的轉錄文本。
實驗結果	Cos. Sim. : ~0.88 Qualitative evaluation 忽略了 ASR 錯誤。	BERTscore:~ 0.88 BLEURT: ~ -0.6 模擬的資料仍有侷限。	Human Rating : ~ 3/5 Fleiss' Kappa: 0.32 評分一致性較低。
侷限性	• 人工標註的轉錄文本可能會忽視 ASR（語音識別）中的音節錯誤。 • 合成數據集可能缺乏臨床複雜性。 • 僅關注單模態可能會漏掉關鍵線索，從而使失語症的句子重建較差。		

四、實驗資料集

本研究主要評估資料集為 AphasiaBank [7]，是失語症研究中規模被廣泛使用的多媒體語料庫之一，涵蓋標準化的訪談與圖片描述任務，並附有臨床測驗資料。包含失語症患者和非失語症對照者，錄製具有統一任務腳本的（如說故事、描述圖片、訪談）的對話影片。

肆、 研究方法

一、資料集準備

(一) AphasiaBank 篩選與處理

本研究主要採用 TalkBank 計畫之 AphasiaBank 失語症語料庫 [7] 作為臨床驗證資料來源。該資料庫包含在統一任務腳本下與失語症患者訪談的語音、影像與轉錄。本研究取得 TalkBank 官方核發之會員資格，並依其研究倫理規範使用該資料。

由於本研究關注於非流暢型失語症患者，因此僅保留診斷標籤為 Broca's aphasia 與 Transcortical Motor aphasia 兩類的訪談影片。經初步處理後共整理出 4,520 句患者英文語句樣本。然而 AphasiaBank 將患者語句裁切的較多，許多單句僅由一至兩個單字構成，缺乏足以還原語意的最低訊息。本研究由研究者人工將時間上連續、語意上隸屬同一表達意圖的相鄰短句合併為單一語句，最終得到 1,128 句合併後的語句樣本用於後續實驗。

(二) 參考答案標註流程

AphasiaBank 雖提供患者實際說出的文字轉錄，卻未提供「患者真正想表達之流暢語意」的對照答案，無法直接作為語意還原實驗的參考答案。雖由臨床專家進行完整標註為理想方式，但 AphasiaBank 中非流暢型子集約含近 70 小時的患者訪談影片，全程仰賴專家標註不只耗費人力與時間，也難以達到模型訓練所需之資料量。

因此，本研究設計流程以建立此參考答案之對照集：由 3 位參與標註者各自反覆觀看每一段患者訪談影片與轉錄腳本，綜合考量影片中之語音、肢體動作、表情、場景與對話上下文，標註其判定之患者真正欲表達的流暢語句。僅當三位標註者對相同樣本的流暢語意達成共識時，方採用該筆樣本進入對照集，成為參考答案。此設計能確保參考之可信度。本研究後續報告之所有實驗結果，皆基於此階段標註之參考答案。

二、評估指標

本研究採用以下兩項指標評估系統輸出與參考答案之間的語意接近程度：

(一) 語意餘弦相似度 Cosine Similarity

以 Sentence-BERT [8] 預訓練模型分別將系統輸出與參考答案編碼為固定長度的句向量，再計算兩向量之間的餘弦相似度，衡量句子在語意嵌入空間中的接近程度。相較於原始 BERT 之 [CLS] 向量存在各向異性（anisotropy）問題，Sentence-BERT 經句對監督微調後所產生的

句向量更適合以餘弦相似度直接比較。此指標可捕捉同義替換、語序重組等表面差異下的語意一致性，避免 BLEU、ROUGE、編輯距離等指標對表面字串過於敏感的問題。

(二) BLEURT 和 BLEURT-20

BLEURT[16] 是 Google Research 提出的學習式語意評估指標，先在合成資料上預訓練，再以人工評分資料微調而成，可同時反映語意相近度、流暢性與表達自然度。其中 BLEURT-20 為官方推薦的多語言檢查點(checkpoint)，支援中文等語言；原始 BLEURT 僅支援英文，且輸出為相對尺度、分數可能為負。本研究以 BLEURT-20 為主要指標，並列原始 BLEURT 作為英文參考，與 Cosine Similarity 互補。

三、系統設計與架構

本研究於系統設計階段觀察 AphasiaBank 之臨床訪談影片，歸納出非流暢型失語症患者實際溝通行為的兩項特性，並依此設計多模態架構，將本研究的系統命名為 AphaSpeak。

觀察一：患者發出的往往是破碎音節，而非完整單字。在 Broca's 與 Transcortical Motor 兩類非流暢型失語症患者語料中，患者於嘗試發出某個詞彙時常僅能說出部分音節，使得單純依賴聲學語音轉文字 (ASR) 之轉錄結果容易出現錯字與遺漏。據此，本研究結合聲音辨識 (Whisper[15]) 與唇語辨識 (ViSpeR[9]) 兩個辨識模型，由聲學與視覺兩個來源交叉驗證，還原患者真正想發出的聲音內容。

觀察二：患者的手勢仍精準指向正確目標。雖然患者說不出物件名稱或命名錯誤，但手指的方向、物件的外型與現場情境仍足以透露真正想表達的意思。所以本研究將後鏡頭場景影像、環境音轉錄與前鏡頭之手勢與表情等視覺線索一併納入，以補充語意。

除了上述兩項，系統也為每位患者建立個人化資料庫，記錄長期累積的表達習慣（特定詞彙的發音偏誤、常用詞彙、生活背景等）。上述模態共同構成了整體架構。

(一) 整體架構

AphaSpeak 採用 iOS App + FastAPI Server 之主從式架構，兩端透過 WebSocket 進行雙向串流。iOS App 負責同時擷取後鏡頭所拍攝之環境場景、前鏡頭所拍攝之患者自拍影像，以及麥克風所收錄之患者語音與環境聲響三種訊號，並以 WebSocket 持續上傳。FastAPI Server 端則進行多模態特徵抽取、特徵融合與大型語言模型推論，最終回傳 5 個候選句子供

患者於 App 中選擇，再由 Server 端的 TTS 模型合成語音回傳並由 App 播放。整體系統與研究架構如圖 4-1 所示。




圖 4-1：系統架構圖

模態可分為四大模塊：語言特徵（Speech Representation）、上下文與場景特徵（Contextual & Scene Information）、行為特徵（Expressive Behavior）與個人化特徵（Personalized Features）。四大模態之特徵在 LLM 端融合並產出排序後之候選句子。

（二）語言特徵

患者語音與唇形動作經由兩條獨立的辨識模型處理。本研究採用 **Whisper** 分別處理對話前期所收錄之環境音（用於擷取對方說話內容）與患者實際說話時之語音（用於理解患者表達的語音內容）。系統直接以失語症患者說話的原始影片進行語音轉文字，而不使用 **AphasiaBank** 的人工轉錄結果，並藉由後續的多模態融合補償這些不足。

ViSpeR（簡稱 **Visper**）[9] 為 TII 於 2024 年發表之多語言視覺語音辨識（AVSR）模型，可由唇形序列辨識口語內容。本研究採用其預訓練權重，並為提升計算效率與即時響應能力作了三項調整：以混合精度（mixed precision）推論降低計算量、以貪婪解碼（Greedy Decoding）取代集束搜尋（beam search）降低延遲，以及以約 15 秒長度為單位分塊式處理（chunk-based streaming），使患者說話的同時即可逐塊計算，最終能在約 3 秒內完成 15 秒唇動序列的計

算。

ASR 與 AVSR 各自獨立推論，由 LLM 比對兩條轉錄結果進行跨模態驗證。此設計除可提升整體準確性外，當兩者出現不一致時，LLM 能即時定位發音模糊之處，並結合其他模態予以補足。

(三) 上下文與場景特徵

此模態結合後鏡頭場景圖與環境音轉錄。在患者按下開始錄影的瞬間 App 即上傳一張後鏡頭拍攝之場景影像。這張影像為模型提供三類線索：患者當下所處的環境、對話對象是誰，以及周遭可能被話語指涉到的物件。環境音則於患者未說話之時間自動於背景錄製，主要捕捉對話對方所說出的內容，並透過 Whisper 轉錄成文字，作為對話上下文輸入。

(四) 行為特徵

此模態處理前鏡頭所拍攝之患者自拍影片，包含關鍵幀提取、手勢偵測、表情偵測與膠卷圖（filmstrip）等步驟。依密集與稀疏兩種採樣密度產出兩組獨立的關鍵幀：密集組供手勢與表情分類器使用，稀疏組則拼接為膠卷圖。

自拍影像每 0.2 秒取一幀，並以 ORB（Oriented FAST and Rotated BRIEF）[10] 特徵描述子計算相鄰幀之間的特徵匹配距離，標準化至 0~1 區間，作為「運動分數」之代表。再對該分數時間序列進行峰值檢測，於波峰之後尋找分數回落至閾值以下的幀作為動作完成點，選取為關鍵幀。這樣可以避開動作進行中那些模糊的過渡幀，只留下動作完成並靜止後的清晰畫面。ORB 在準確率與運算速度上，相較於光流、區塊匹配(Block Matching)與基於 CLIP[17] 的方法等替代方案皆具明顯優勢，相關驗證實驗詳見附錄一。

所選之關鍵幀送入手勢辨識模組。本研究採用 HaGRIDv2 [11] 所提供之預訓練 YOLO 模型，辨識 call、dislike、fist、four 等 33 種常用手勢。輸出為帶時間戳之手勢標籤序列，並合併相鄰同標籤、丟棄持續時間過短者，以降低雜訊。同一批關鍵幀並行送入表情辨識模型。本研究採用基於 Xception [12] 架構之預訓練模型，辨識表情特徵協助 LLM 判斷患者當下之語氣與情感傾向。

這兩個分類器只輸出離散的類別標籤，會遺漏手勢指向、指涉物件、細微表情變化等原始視覺線索。為彌補此一資訊損失，本研究將所選關鍵幀橫向拼接成一張「膠卷圖」[13]，作為 VLM 的另一張圖片輸入，使 LLM 不僅能讀到分類器的離散標籤，亦能直接觀察患者當

下之完整畫面。此外，本研究透過 YOLO 對膠卷圖進行患者位置校正，將臉部與手部穩定框定於固定區域內。

本模態採「密集標籤序列 + 稀疏膠卷圖」之並行設計。原因是：若僅提供分類器產生的離散標籤，大型語言模型難以從 **call**、**fist** 這些抽象類別推測出患者實際指向的方向與物件；反之，若將所有關鍵幀全數拼入膠卷圖，不僅視覺語言模型(VLM)的圖像 **token** 成本會隨張數線性上升，過多畫格也會稀釋注意力，使模型難以聚焦於關鍵動作。因此密集組產生高頻時序標籤、稀疏組補足真實畫面，兩者互補。

(五) 個人化特徵 (Personalized Features)

本研究為每位患者建立一份個人化檔案，記錄其常見發音錯誤與拼寫、常去的地點、常用語句與口頭禪，以及職業、興趣、家庭成員等個人背景。此檔案於每次 LLM 推論時，以記憶的形式注入提示詞最上層，使模型在分析其餘模態特徵之前，先建立對該患者之先驗認識。固定輪次的對話結束後，由 LLM 自動總結並更新該檔案。

四、Prompt 設計

本研究於初步實驗中發現 **Chain-of-Thought** 推理可有效提升 LLM 於本任務之表現，對每個推理步驟施加字數上限以控制延遲。本研究將上述各模態特徵連同推理指引一併嵌入提示詞，引導 LLM 依序分析各模態並整合資訊，最後產出 5 個按信心程度排序之候選句子。

五、Choice-Filtered Distillation (選項篩選蒸餾) 方法

本系統推論主體採用 Google Gemini 2.5 Flash 作為 LLM，在本研究進行的多模型比較實驗中，Gemini 2.5 Flash 在多模態推理品質與回應速度上均達到本任務的需求，然而其為雲端服務，在隱私性與在地端部署上存在限制。為此，本研究進一步藉由蒸餾訓練一個小型專家模型，期能同時降低運算成本並提升語句還原的準確度。

(一) 蒸餾資料生成流程：

因為系統輸出為多個候選句之排序列表，單句目標無法涵蓋此一輸出結構。本研究因此設計此資料生成流程，使小模型學到正確語句特性，以及如何按信心程度排序候選句：

1. 教師模型候選選項生成：以 Gemini 2.5 Flash 為教師模型，對每一筆多模態輸入產生 5 個候選還原句子。

2. 標準答案注入：將 5 個候選中 Cosine Similarity 最低者刪除，並將參考答案插入候選第一項，同時將剩餘的選項依據與正確答案的 Cosine Similarity 排序（由高到低），使 top-1 永遠為參考答案，top-2 至 top-5 則按相似度遞減排列。

(二) 模型訓練：採用 QLoRA (Quantized Low-Rank Adaptation) [14] 對學生模型在蒸餾資料集上，進行參數微調。

伍、研究結果

一、輸出準確度實驗：Top-K 候選準確率

本實驗量化系統還原失語症語句的能力，給定一段失語症患者表達影片、場景圖，系統輸出 K 個候選還原句子。將每個候選句子與參考答案計算 Cosine Similarity，若 Top-K 候選中至少有一個與參考答案的 Cosine Similarity 大於等於閾值，即視為該樣本被「成功還原」。




圖 5-1：系統語句還原準確度

圖 5-1 呈現的是系統提供多個建議選項的準確率。綠色曲線代表在最嚴苛的 Cos.Sim ≥ 0.85 門檻下的準確率。單一選項時最佳猜測的準確率為 64%；當候選句增加到 Top-3 時，準確率提升到 80%，且這已經非常接近 Top-5 選項的 84%。結果顯示系統能夠在少數幾個選項內涵蓋正確語意。同時，AphaSpeak 相較於純文字 LLM（紫色曲線），大約提升了 10% 的表現，說明多模態資訊確實能提供有效線索，提升語意還原能力。

二、消融實驗 (Ablation Study)：各模態貢獻分析

此實驗欲分析各個模態對於輸出準確度實驗約 10% 的提升分別貢獻多少。本實驗逐步將

模態加入基準，以標準化分數量化每一步的相對貢獻。設 X_{min} 為僅使用 Whisper 的基準（0 %）， X_{max} 為完整 多模態結果的最高分（100 %），則：

$$NormScore = \frac{X - X_{min}}{X_{max} - X_{min}}$$

依照語音轉文字（Whisper-only）、場景圖特徵（Scene）、上下文（Contextual Information）、唇語特徵（Visper）與關鍵幀計算（Key Frame，包含行為特徵的手勢、表情與膠卷圖）的順序加入模態。每加入一個模態，都計算在提供當前模態組合下，系統在資料集上的還原表現。




圖 5-2：消融實驗結果

實驗結果發現：

- (一) 場景與上下文特徵各自帶來約 30~40% 的提升，這顯示語句還原在理解患者身處的空間與對話上下文脈絡後，候選語句將會更加準確。
- (二) 唇語讀取 與行為特徵，合計貢獻約 22 %。Visper 的唇語讀取補強了 Whisper 在嚴重失語症下的辨識弱點；行為特徵則提供患者如肢體語言和情緒的資訊。
- (三) AphaSpeak 設計中，各個模態都能提供有效線索，使 LLM 更加瞭解患者的表達意圖，從而提升失語症語句的還原能力。

三、系統延遲優化實驗

本實驗驗證系統各項計算優化技術的效果。根據 National Aphasia Association 之溝通指引，對話對象應給予失語症患者至少 5 秒的回應時間；本研究據此將 5 秒設為系統延遲上限。經各項優化後，計算耗時由約 18 秒壓縮至 4 秒以內，成功落在此門檻之內。

(一) 串流式並行運算(Streaming Concurrent Computation)

此優化欲使後端運算在患者錄製過程中就同步進行，而不是等錄製結束才啟動。為此，

iOS App 透過 WebSocket 將錄製中的多模態資料即時送往 FastAPI 伺服器。不再等整段錄完才一次上傳。

如此，後端便能邊接收邊運算：ORB 動態評分隨幀同步推進；影像與語音以約 15 秒為一個 chunk 送入下游運算 (Whisper、ViSpeR、手勢、表情等)。患者結束發話的瞬間，大部分特徵已經計算完畢，整體等候時間因此縮短。

(二) 分層任務排程

串流式並行運算讓多模態特徵能與說話過程同步進行，但模型運算和持續接收的影像幀都要佔用伺服器資源。若所有工作共用同一條執行路徑，模型推論將阻塞高頻的幀接收與動態評分，使串流處理與推論運算互相牽制。本系統依时序需求與阻塞特性將工作分成三層，如圖 5-3 所示。




圖 5-3：伺服器分層任務排程架構

1. 串流接收與動態評分並行：WebSocket 收到的影像幀先進入非同步佇列，接收路徑與 ORB 動態評分路徑解耦。
 2. 多模態並行推理與線程隔離：Whisper、ViSpeR、手勢與表情偵測各自跑在獨立的服務進程上，主伺服器以 async 並發方式同時對各進程發出請求，多個模型就能並行計算。影片編碼等高運算負載的工作則交給獨立的執行緒池，跟即時任務隔開。
 3. 延後背景任務：個人化語言模式分析在系統閒置時才啟動，不佔用即時運算路徑。
- 這樣的分層使各類任務在資源上彼此隔離，即時運算路徑不被重運算阻塞。




圖 5-4：
各項優化下的計算耗時

四、Choice-Filtered Distillation 效果實驗

(一) 實驗設定

本實驗驗證 Choice-Filtered Distillation（選項篩選蒸餾）微調小型 LLM 的效果。以 85% 的樣本作為訓練集，15%作為測試集。使用 Gemini 2.5 Flash 做為教師模型，使用 QLoRA 進行微調。

(二) 實驗結果




圖 5-5：學生與教師模型於失語症語意還原任務之效能比較

本研究於約 14B 參數規模之內的之開源模型中（涵蓋 Qwen、Gemma、Minstral 系列）進行比較，最終選用 Minstral 3 14B 作為學生模型。選擇依據為三項關鍵條件：微調後之準確度、結構化輸出（5 個排序候選句）之格式穩定性、微調收斂穩定性。Gemma 系列於微調過程中常產出錯誤的結構化輸出，無法穩定維持 5 個選項句排序格式；Qwen 系列在英文失語症資料上改善幅度有限。Minstral 3 14B 為同時滿足上述三項條件之最佳候選。

經 QLoRA 微調後，14B 學生模型在 BLEURT-20 與 Cosine Similarity 上略優於教師模型（Gemini），差距約 0.04。此結果源自三項因素：(1) 篩選步驟排除教師的錯誤輸出，提升訓練資料品質；(2) 人工參考答案納入候選集，為學生模型提供高品質的監督訊號；(3) 排序任務本身使學生模型學習區分優劣候選句的相對品質，強化了其對語義正確性的判別能力。

五、系統效果驗證

(一) 實驗設定

採用 AphasiaBank 真實患者訪談影片進行 AphaSpeak 系統完整效果驗證。中文資料集自 AphasiaBank 取使用中文之患者訪談影片進行測試，作為跨語言能力的初步驗證。

(二) 實驗結果

表 5-1：AphaSpeak 於英文與中文失語症資料集上的驗證結果

Metrics	English	Chinese
BLEURT-20	0.6129	0.4300
BLEURT	-0.067	
Cosine Similarity	0.9134	0.8299

英文資料集上，系統獲得 Cosine Similarity 為 0.91 顯示系統還原句子與人工標註的參考答案在語意高度相似；BLEURT-20 達 0.61 在句子層級的評估中亦佳。

中文方面 Cosine Similarity 達到 0.83、BLEURT-20 達到 0.43，雖然數值遜於英文，但仍足以顯示系統架構具備跨語言拓展的潛力。由於多模態融合、ORB 關鍵幀、手勢與表情辨識模組皆與語言無關，只要替換 LLM 與語音、唇語模型，即可應用於更多不同語言。


六、範例展示

(一) 個人故事敘述範例案例

Interviewer	“Tell me a story about something important in your life?”
Patient	“um words uh this this pɹɛʃɪn of a group um many many years ago. uh I don't know that sometimes it's easy. w words and sentences.”
Gemini 2.5 Flash (純文字)	“This group formed many years ago... sometimes it's easy to forget.”
AphaSpeak (Ambient Audio + Selfie Video)	“Many years ago, I found it difficult to express myself in words and full sentences, particularly when under group pressure.”

患者實際上從未提及「忘記 (forget)」，顯示出純文字 LLM 之模糊且錯誤的輸出。本研究開發之 AphaSpeak 從語音與自拍影像中，成功辨識出 “pɹɛʃɪn of a group” (pressure of a group) 與 “words and sentences” 兩個關鍵語意，並正確重現出 “group pressure → difficulty expressing in words and sentences” 這個因果關係。

(二) 圖片描述範例案例

	
Interviewer	“Tell me a story about what's going on in that picture.”

圖片來源：AphasiaBank。Cat [圖片]。

TalkBank。https://talkbank.org/aphasia/

Patient	“and then she has a little the she's got to have that. and then this [point dad] grandma [point fireman] or g uh grandma she has that. and then then grandma no [wave hands] it's that's not right...”
Gemini 2.5 Flash (純文字)	“She had to go and see her father.”
AphaSpeak (多模態)	“The girl wants the cat, and her father is in the tree trying to help. The firefighters are bringing a ladder because the father needs to come down.”

此案例中，患者用 “grandma” 稱故事中所有角色，無法分辨。然而自拍畫面中的患者指向圖片中不同的對象；純文字方案丟失了「貓」、「消防員」、「梯子」等絕大多數關鍵資訊。而 AphaSpeak 則透過場景影像與患者指示的手勢，成功重建出畫面中女孩、父親與消防員之間的正確關係。

兩個案例共同呈現的結論是：純文字的大型語言模型因為線索不足，容易產生幻覺或遺漏資訊；AphaSpeak 則藉由多模態融合讓系統真正理解患者的意圖。

陸、 討論與結論

一、準確率提升：AphaSpeak 整合視覺與情境資訊，不僅修正原始 ASR 的錯誤，也補上視覺與上下文線索，使系統能更準確地還原患者的語意，將 BLEURT-20 提升至 0.61，Cosine Similarity 提升至 0.91。

二、高效部署：透過架構優化與 Choice-Filtered Distillation(選項篩選蒸餾)，系統能以較低的運算成本部署，並將延遲控制在 4 秒以內。

三、促進自然溝通：簡潔的 App 介面使用選擇語句的回答方式，能有效消除對話中的障礙，讓患者自然地參與日常生活與社交互動。

柒、 未來展望

一、本研究未來將與專業語言治療師合作，於地區醫院在 IRB 規範下邀請真實失語症患者試用本系統，蒐集臨床使用者回饋，作為後續實驗設計與系統優化之依據。

二、在模型架構方面，未來將嘗試將手勢、表情等行為特徵訓練為一混合式視覺編碼器(hybrid vision encoder)，直接注入大型語言模型之輸入端，取代現行以文字描述傳遞多模態資訊的方式，使模型能保留更豐富的細部特徵，進一步提升語句重建之準確性。

捌、 參考資料

- [1] National Aphasia Association. (n.d.). *Aphasia FAQs*. <https://www.aphasia.org/aphasia-faqs/>
- [2] Aphasia Library. (n.d.). *Communication tips*. <https://aphasialibrary.org/communication-tips/>
- [3] AssistiveWare. (2020). *From Proloquo2Go with a message about washing germs off for the coronavirus* [Image]. <https://www.assistiveware.com/blog/using-proloquo2go-to-talk-about-the-coronavirus>
- [4] van Vaals, S., Matuskevych, Y., & Tsiwah, F. (2025). Generating completions for fragmented Broca’s aphasic sentences using large language models. *IEEE Journal of Biomedical and Health Informatics*. Advance online publication. <https://doi.org/10.1109/JBHI.2025.3639109>
- [5] Shi, Y., Qin, Y., Yu, K., Wei, X., Liu, J., Liu, F., Xu, S., Li, J., Xu, J., Abbasi, A., Xiong, C., Yu, F., & Zheng, T. (2025). Serving individuals with language impairments using automatic speech recognition models and large language models: Challenges and opportunities. *arXiv*. <https://arxiv.org/abs/2506.06566>
- [6] Manir, S. B., Islam, K. M. S., Madiraju, P., & Deshpande, P. (2024). LLM-based text prediction and question answer models for aphasia speech. *IEEE Access*, 12. <https://doi.org/10.1109/ACCESS.2024.3443592>
- [7] MacWhinney, B., Fromm, D., Forbes, M., & Holland, A. (2011). AphasiaBank: Methods for studying discourse. *Aphasiology*, 25(11), 1286–1307.
- [8] Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. <https://doi.org/10.18653/v1/D19-1410>
- [9] Narayan, S., Djilali, Y. A. D., Singh, A., Le Bihan, E., & Hacid, H. (2024). ViSpeR: Multilingual audio-visual speech recognition. *arXiv*. <https://arxiv.org/abs/2406.00038>
- [10] Rublee, E., Rabaud, V., Konolige, K., & Bradski, G. (2011). ORB: An efficient alternative to SIFT or SURF. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 2564–2571).
- [11] Nuzhdin, A., Nagaev, A., Sautin, A., Kapitanov, A., & Kvanchiani, K. (2024). HaGRIDv2: 1M images for static and dynamic hand gesture recognition. *arXiv preprint*. <https://arxiv.org/abs/2412.01508>
- [12] Azrien, E. A., Hartati, S., & Frisky, A. Z. K. (2024). Regularized Xception for facial expression recognition with extra training data and step decay learning rate. *IAES International Journal of Artificial Intelligence (IJ-AI)*, 13(4), 4703–4710.
- [13] Kim, W., Choi, C., Lee, W., & Rhee, W. (2024). An image grid can be worth a video: Zero-shot video question answering using a VLM. *IEEE Access*, 12, 193057–193075. <https://doi.org/10.1109/ACCESS.2024.3517625>
- [14] Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems* (Vol. 36, pp. 10088–10115).

- [15] Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning (ICML)* (pp. 28492– 28518).
- [16] Sellam, T., Das, D., & Parikh, A. P. (2020). BLEURT: Learning robust metrics for text generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)* (pp.7881– 7892).
- [17] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)* (pp. 8748– 8763).

附錄

附錄一：關鍵幀提取演算法比較實驗

本附錄詳列本研究於選定 ORB (Oriented FAST and Rotated BRIEF) [10] 作為前鏡頭自拍影片之關鍵幀提取演算法之前所進行的演算法比較實驗。

一、實驗設定

使用 AphasiaBank 中文患者訪談影片與轉錄的動作標記，比較 7 種可用於計算幀間差異的演算法，包含：稠密光流法 (Dense Optical Flow)、幀差法 (Frame Differencing)、區塊比對法 (Block Matching)、特徵點追蹤 (Lucas-Kanade Feature Tracking)、直方圖差異法 (Histogram Difference)、ORB (Oriented FAST and Rotated BRIEF) 與 CLIP[17] 嵌入向量餘弦相似度。

由於 AphasiaBank 原始資料僅提供動作標記，但是未提供動作出現的時間戳標註，本研究以視覺大型語言模型進行半自動標註，建立標準答案動作位置 (V_{RA})，以視覺大型語言模型對自拍影片每 0.2 秒進行一次動作評分，即評分該動作標記在此幀出現的機率，得到動作分數時序 V_A 。對 V_A 進行峰值檢測，找出動作轉換點作為 V_{RA} 。各演算法產出之關鍵幀集合 V_K 與 V_{RA} 比對，允許正負 0.2 秒之誤差，準確率即為 $\frac{V_K \cap V_{RA}}{V_{RA}}$ ，同時記錄處理時間 (秒) 與多餘幀比例 $\frac{V_K \cap V_{RA}'}{V_K}$ 。

二、實驗結果

附表 1：關鍵幀演算法效果比較

演算法	處理時間（秒）	準確率	多餘幀比例
稠密光流法	17.01	43.62 %	87.09 %
幀差法	0.44	14.42 %	84.40 %
區塊比對法	23.06	58.51 %	86.31 %
特徵點追蹤	1.91	41.13 %	87.08 %
直方圖差異法	0.52	56.56 %	85.34 %
ORB	2.13	58.63 %	86.16 %
CLIP 嵌入向量餘弦相似度	0.65	39.78 %	85.92 %

ORB 與區塊比對法準確率並列第一（58.63 % 與 58.51 %），但前者僅 2.13 秒、較後者快約十倍，亦優於同等級的稠密光流法（17.01 秒/43.62 %）。速度更快的 CLIP 嵌入向量餘弦相似度（0.65 秒）準確率僅 39.78 %，推測為其編碼之語意向量對相鄰自拍畫面之手勢差異不夠敏感。綜合考量以上實驗結果，本研究採用 ORB 進行行為特徵之前處理。